correlacao_notebook

July 3, 2021

[15]:
```
library(tidyverse)
library(mvtnorm)
options(repr.plot.width=4, repr.plot.height=4)
```

0.1 Correlação linear de Pearson

Apresenta os comandos em R para o cálculo da covariância amostral e do coeficiente de correlação de Pearson entre as variáveis Y e X.

Os calculos são feitos *manualmente* com as fórmulas disponíveis aqui e também utilizando as funções do R.

Inventando um conjunto de dados

[2]:
```
rpop <- 0.5
s1 <- 20; s2 <- 30
m1 <- 100; m2 <- 50
n <- 10
covs <- rpop * sqrt(s1) * sqrt(s2)
cov_mat <- matrix(c(s1, covs,
                    covs, s2),
                  2,2)
set.seed(2)
df <- mvtnorm::rmvnorm(n = n, mean = c(m1, m2), sigma = cov_mat) %>%␣
 ↪as_tibble() %>%
      rename(X = V1, Y = V2) %>% round(2)
```

```
Warning message:
"`as_tibble.matrix()` requires a matrix with column names or a `.name_repair`
argument. Using compatibility `.name_repair`.
This warning is displayed once per session."
```

A tabela de dados

[3]:
```
df
```

X	Y
96.39	49.84
105.37	46.00
99.82	50.60
102.73	49.63
108.33	51.79
103.04	55.76
96.99	43.96
104.70	39.96
103.81	51.31
104.89	53.59

O gráfico de dispersão

[4]:
```
ggplot(df, mapping = aes(x = X, y = Y)) +
    geom_point()
```

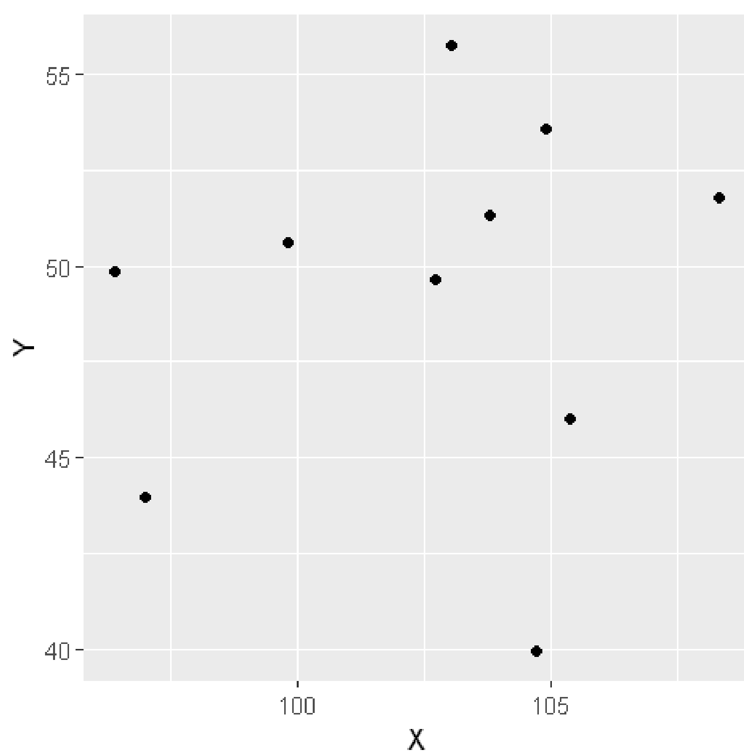

Covariância: cálculos intermediários passo-a-passo

[5]:
```
df = df %>%
    mutate(dX = X - mean(X),
           dY = Y - mean(Y),
           dX2 = dX^2,
           dY2 = dY^2)
```

```r
df
```

X	Y	dX	dY	dX2	dY2
96.39	49.84	-6.217	0.596	38.651089	0.355216
105.37	46.00	2.763	-3.244	7.634169	10.523536
99.82	50.60	-2.787	1.356	7.767369	1.838736
102.73	49.63	0.123	0.386	0.015129	0.148996
108.33	51.79	5.723	2.546	32.752729	6.482116
103.04	55.76	0.433	6.516	0.187489	42.458256
96.99	43.96	-5.617	-5.284	31.550689	27.920656
104.70	39.96	2.093	-9.284	4.380649	86.192656
103.81	51.31	1.203	2.066	1.447209	4.268356
104.89	53.59	2.283	4.346	5.212089	18.887716

Soma dos produtos cruzados (SQ_{YX})

[6]:
```r
SQyx = sum(df$dX * df$dY)
```

Covariância entre X e Y: $S_{YX} = \frac{SQ_{YX}}{n-1}$

[7]:
```r
Syx = SQyx / (n-1)
Syx
```

2.62756888888889

Covariância: função no R

[8]:
```r
cov(df$X, df$Y)
```

2.62756888888889

Correlação de Pearson: cálculos intermediários Soma dos quadrados de X (SQ_X) e de Y (SQ_Y)

[9]:
```r
SQx = sum(df$dX^2)
SQy = sum(df$dY^2)
```

Coeficiente de Correlação de Pearson: passo-a-passo

[10]:
```r
r = SQyx / (sqrt(SQy) * sqrt(SQx))
r
```

0.147226752957727

Coeficiente de Correlação de Pearson: função no R

[11]:
```r
cor(df$Y, df$X)
```

0.147226752957727

Teste de hipóteses sobre o r: passo-a-passo

[12]:
```
tcalculado = r / sqrt((1 - r^2)/(n-2))
tcalculado
```

0.421007963528141

t crítico bicaudal

[13]:
```
tcritico = qt(p = 0.975, df = n-2)
tcritico
```

2.30600413520417

Se $|t_{caclulado}| < |t_{crtico}|$: aceita H_0

Se $|t_{caclulado}| \geq |t_{crtico}|$: rejeita H_0

Teste de hipóteses sobre o r: função no R

[14]:
```
cor.test(df$Y, df$X)
```

```
        Pearson's product-moment correlation

data:  df$Y and df$X
t = 0.42101, df = 8, p-value = 0.6848
alternative hypothesis: true correlation is not equal to 0
95 percent confidence interval:
 -0.5316857  0.7109496
sample estimates:
      cor
0.1472268
```